

四种通信中间件统一测试需求文档

版本：1.0

1 目的与范围

本需求文档用于规范 VSOA、DDS、MQTT 和 Zenoh 的统一测试。测试系统应统一测试参数、测试流程、指标定义、计算公式、结果格式和横向比较方法，保证测试结果可比较、可复现和可追溯。

测试内容包括：

- 不同消息大小、发送速率和通信拓扑下的性能；
- 延迟、吞吐、CPU、内存和丢包率；
- 启动、发现、重连和故障恢复；
- 数据完整性、重复、乱序和消息丢失；
- 各中间件特有的 QoS 和功能特性。

2 统一测试参数

所有中间件测试适配器应支持以下参数：

参数	说明
module_name, module_version	中间件名称和版本
scenario_name	测试场景名称
payload_size_bytes	应用层 payload 大小，不含协议头和测试元数据
message_count	正式测试发送的消息数量
publish_rate_hz	计划发送速率；0 表示不限速
publisher_count	发布者数量
subscriber_count	订阅者数量
transport_mode	TCP、UDP、QUIC 或其他传输模式
qos_profile	QoS、可靠性、持久化和队列配置
warmup_seconds	预热时间，不计入正式指标
drain_seconds	停止发送后的排空时间

参数	说明
duration_seconds	正式测试持续时间
repeats	每个测试条件的重复次数
network_profile	延迟、抖动、丢包率和带宽限制
random_seed	随机种子

推荐消息大小为：

1KiB, 4KiB, 16KiB, 32KiB, 48KiB, 64KiB, 256KiB, 1MiB.

其中：

1KiB = 1024bytes, 1MiB = 1048576bytes.

推荐拓扑如下：

拓扑	发布者	订阅者	目的
点对点	1	1	基础延迟和吞吐
一对多	1	4	广播和扇出
多对一	4	1	消息汇聚
多对多	4	4	并发通信

3 标准测试场景

编号	场景	主要要求
S01	点对点低延迟	1P/1S, 1 KiB, 100 Hz 和 1000 Hz
S02	消息大小扫描	固定拓扑、速率和 QoS, 遍历消息大小矩阵
S03	大消息吞吐	64 KiB、256 KiB、1 MiB, 使用最大稳定速率
S04	发送速率扫描	100 Hz、1000 Hz、5000 Hz 和最大稳定速率
S05	一对多广播	1P/4S, 统计总交付和单订阅者结果
S06	多对一汇聚	4P/1S, 统计各发布者和总结果
S07	多对多并发	4P/4S, 统计交付矩阵和资源消耗
S08	长时间运行	至少 5 分钟, 观察延迟漂移和内存增长
S09	弱网与恢复	1%、5%、10% 丢包及不同延迟、抖动
S10	启动与发现	冷启动、热启动、多端点发现和超时

编号	场景	主要要求
S11	重连与故障恢复	进程、Broker、Router 或网络故障后的恢复
S12	数据正确性	校验长度、校验和、缺失、重复和乱序

每个测试条件至少重复 5 次，正式测试推荐重复 10 次。每条消息必须包含唯一序列号、发送时间戳、payload 长度和校验和。

4 统一指标定义

4.1 延迟

第 i 条消息的单向端到端延迟为：

$$L_i = \frac{t_{\text{recv},i} - t_{\text{send},i}}{10^6} \text{ ms.}$$

其中发送端和接收端必须使用同一单调高精度时钟。平均延迟为：

$$\text{latency_ms} = \frac{1}{n} \sum_{i=1}^n L_i.$$

仅统计通过序列号、长度和校验和验证的唯一消息；预热消息和恢复阶段消息不纳入原始延迟统计。

4.2 P95、P99 和标准差

将有效延迟样本升序排列为 $x_0, \dots, x_{n-1}$ 。分位数位置统一为：

$$h = (n - 1)p,$$

其中 $p = 0.95$ 或 $p = 0.99$ 。整数位置直接取值，非整数位置使用线性插值：

$$\text{latency_p95_ms} = P_{95}(L), \quad \text{latency_p99_ms} = P_{99}(L).$$

延迟标准差统一使用总体标准差：

$$\text{latency_std_ms} = \sqrt{\frac{1}{n} \sum_{i=1}^n (L_i - \bar{L})^2}.$$

无有效样本时，延迟相关指标必须为 `null`。

4.3 抖动

对同一发布者到同一订阅者的消息按序列号排序：

$$J_i = |L_{i+1} - L_i|, \quad \text{jitter_ms} = \frac{1}{n-1} \sum_{i=1}^{n-1} J_i.$$

`jitter_ms` 不得直接使用 `latency_std_ms` 代替。

4.4 吞吐量

设 B 为 payload 字节数, N_r 为有效唯一交付数, T_d 为从首条正式发送到最后一条计入接收消息的时间窗口, 则:

$$\text{throughput_mbps} = \frac{N_r \times B \times 8}{T_d \times 10^6}.$$

同时记录发送吞吐:

$$\text{offered_throughput_mbps} = \frac{N_s \times B \times 8}{T_s \times 10^6},$$

其中 N_s 为实际成功发送数, T_s 为实际发送窗口。吞吐量只计算 payload, 不计算协议头、测试元数据和恢复消息。

4.5 CPU 和内存

资源统计范围为当前中间件运行所必需的进程, 包括发布者、订阅者、Broker、Router 和 Discovery 服务; 不包括通用测试控制程序。

CPU 使用率以一个逻辑核心为 100%:

$$\text{cpu_percent} = \frac{\sum \Delta t_{\text{cpu}}}{T_{\text{resource}}} \times 100.$$

内存统一使用 RSS 峰值, 单位为十进制 MB:

$$\text{memory_mb} = \frac{\max(\sum \text{RSS}_{\text{process}})}{10^6}.$$

4.6 丢包率

设 N_{expected} 为预期交付数, 点对点场景中 $N_{\text{expected}} = N_s$, 广播场景中 $N_{\text{expected}} = N_s \times N_{\text{subscriber}}$, 则:

$$\text{packet_loss} = \frac{N_{\text{expected}} - N_{\text{received,before}}}{N_{\text{expected}}}.$$

恢复完成后的丢包率为:

$$\text{final_packet_loss} = \frac{N_{\text{expected}} - N_{\text{received,after}}}{N_{\text{expected}}}.$$

同时记录网络注入丢包率、重复数量、乱序数量、损坏数量、恢复数量和恢复时间。

4.7 启动、发现和测试时间

启动时间定义为测试控制程序开始到所有必要组件 ready 的时间:

$$\text{startup_time_ms} = (t_{\text{ready}} - t_{\text{harness start}}) \times 1000.$$

发现时间定义为发现、匹配或订阅完成的时间:

$$\text{discovery_time_ms} = (t_{\text{discovery complete}} - t_{\text{discovery start}}) \times 1000.$$

如果测试模式不支持发现, 应将 `discovery_supported` 设置为 `false`, 并将 `discovery_time_ms` 设为 `null`。

`test_start_time` 和 `test_end_time` 统一采用 UTC ISO 8601 格式, 例如:

2026-09-09T08:00:00.123Z

5 横向比较要求

两组结果只有在以下条件一致时，才能直接比较：

- payload 大小、发送速率和测试时长；
- 发布者数量、订阅者数量和拓扑结构；
- 传输模式、QoS 和可靠性语义；
- 网络延迟、抖动、丢包率和带宽；
- warm-up、drain、重复次数和统计公式版本；
- 操作系统、硬件和测试环境。

报告至少支持以下比较：

1. 同一消息大小下的中间件比较；
2. 同一发送速率下的中间件比较；
3. 同一拓扑下的中间件比较；
4. 同一 QoS 或可靠性语义下的比较；
5. 同一中间件不同消息大小、速率和拓扑的纵向比较；
6. 正常网络与弱网条件下的性能退化比较。

结果必须按以下字段分组，不能混合平均：

```
module_name, scenario_name, payload_size_bytes, publish_rate_hz,
publisher_count, subscriber_count, transport_mode, qos_profile, network_profile.
```

延迟、P95、P99、标准差、CPU、内存、丢包率和启动时间通常越低越好，吞吐量通常越高越好。排名必须基于相同测试条件，不能仅根据所有场景的总体平均值排名。

6 结果与验收要求

每轮结果至少包含：

- 完整实际配置和环境信息；
- 本文定义的全部统一指标；
- 有效样本数、发送数、接收数和预期交付数；
- 重复、乱序、损坏、恢复和错误信息；
- 测试时间窗口和指标定义版本。

统一结果字段包括：

```
latency_ms      latency_p95_ms  latency_p99_ms  latency_std_ms
throughput_mbps cpu_percent     memory_mb       packet_loss
startup_time_ms discovery_time_ms test_start_time  test_end_time
```

验收标准：

1. 四种中间件使用相同的指标定义版本和统计方法；
2. P95、P99 使用统一的线性插值方法；
3. 延迟标准差使用总体标准差；

4. 吞吐量使用有效 payload 和统一时间窗口；
5. CPU、内存和丢包率的统计范围明确；
6. 无有效样本、未测量或不适用的指标使用 `null`；
7. 每个测试条件至少有 5 次有效重复；
8. 汇总结果可以由单轮结果重新计算；
9. 结果文件可以通过统一 JSON Schema 校验；
10. 报告能够按消息大小、速率、拓扑、QoS 和网络条件进行横向比较。